

LAPORAN PRAKTIKUM MINGGU KE-5 KONTROL CERDAS

Minggu Ke-5

Nama : Fajril Nurfianto
NIM : 224308082
Kelas : TKA-7D
Akun GitHub (Tautan) : <https://github.com/fajrlnurfianto28>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Pada praktikum ini, mahasiswa diharapkan dapat:

1. Memahami konsep *Deep Reinforcement Learning* (DRL) dalam control sistem kompleks.
2. Mengimplementasikan *Deep Q-Network* (DQN) untuk control otomatis.
3. Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Deep Reinforcement Learning (DRL) adalah paradigma kecerdasan buatan yang mengintegrasikan pengambilan keputusan berurutan dari *Reinforcement Learning* (RL) dengan kemampuan representasi data berdimensi tinggi dari *Deep Learning* (DL). DRL melatih agen cerdas untuk menghasilkan keputusan optimal di lingkungan dinamis, guna memaksimalkan reward kumulatif jangka panjang. Pendekatan ini krusial untuk mengendalikan sistem kompleks, karena mampu menangani ruang state dan action yang luas atau kontinu masalah yang sulit diatasi RL klasik. Contohnya, pada sistem otonom, data sensor visual mentah diproses oleh jaringan saraf tiruan mendalam (*deep neural networks*) untuk mengekstrak fitur relevan sebelum pengambilan keputusan (Sutton & Barto, 2018).

Implementasi utama DRL, menggunakan jaringan saraf sebagai aproksimator fungsi Q, menggantikan Q-Table tradisional yang tidak efisien.

Jaringan ini menerima state lingkungan sebagai input dan menghasilkan estimasi nilai Q untuk setiap action potensial. Stabilitas DQN dalam kontrol otomatis bergantung pada dua mekanisme kunci yaitu, *Experience Replay Buffer* dan *Target Network*. Perbandingan DRL (seperti DQN) dengan metode konvensional (PID, *Sliding Mode Control*, atau *Model Predictive Control-MPC*) menunjukkan keunggulan DRL dalam sistem nonlinier, tidak pasti, dan *model-free*, di mana belajar kebijakan adaptif tanpa model matematika eksplisit berbeda dengan metode konvensional yang memerlukan model akurat.

DRL juga unggul dalam optimasi reward jangka panjang, seperti perencanaan rute, sementara konvensional lebih fokus pada performa instan. Namun, konvensional menawarkan kestabilan terbukti secara matematis dan interpretasi yang jelas, esensial untuk aplikasi kritis seperti robot industri atau pesawat. Sebaliknya, DRL memerlukan komputasi pelatihan tinggi dan bersifat black box. Oleh karena itu, pendekatan hibrida sering digunakan DRL untuk perencanaan strategis tingkat tinggi, dan konvensional untuk eksekusi presisi tingkat rendah.

4. Diskusi

1) Apa kelebihan dan kelemahan DQN dibandingkan metode *Q-Learning* klasik?

➤ Kelebihan

Deep Q-Network (DQN) merupakan pengembangan fundamental dari *Q-Learning* klasik yang dirancang untuk mengatasi masalah skalabilitas dan kompleksitas data. Kelebihan DQN terletak pada kemampuannya menangani ruang *state* yang sangat besar, bahkan kontinu, yang mustahil dilakukan oleh *Q-Learning*. Hal ini dicapai berkat penggunaan jaringan saraf tiruan mendalam (*deep neural networks*) sebagai aproksimator fungsi Q, yang memungkinkan agen untuk menggeneralisasi pengetahuan dari *state* yang pernah dilihat ke *state* baru yang belum pernah ditemui. Selain itu, penggunaan jaringan saraf jauh lebih efisien dalam memori karena hanya menyimpan bobot jaringan alih-alih seluruh Tabel Q yang ukurannya dapat bertambah secara eksponensial.

➤ **Kekurangan**

DQN memerlukan sumber daya komputasi yang jauh lebih tinggi dan waktu pelatihan yang lebih lama dibandingkan *Q-Learning* klasik karena proses pelatihan jaringan saraf yang intensif. DQN rentan terhadap ketidakstabilan pelatihan dan divergensi (kegagalan konvergensi), sehingga memerlukan teknik stabilisasi tambahan seperti *Experience Replay Buffer* dan *Target Network*. *Q-Learning* klasik, DQN terbatas pada ruang aksi diskret tidak dapat secara langsung mengontrol sistem dengan aksi kontinu (misalnya, torsi variabel), yang merupakan kebutuhan umum dalam robotika modern. Sebaliknya, *Q-Learning* klasik jauh lebih stabil dan ringan secara komputasi, serta memiliki jaminan konvergensi yang kuat secara teoritis, meskipun hanya efektif dalam lingkungan dengan ruang *state* yang kecil dan terbatas.

- 2) Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?

Untuk menerapkan *Deep Q-Network* (DQN) dalam pengendalian sistem dinamis seperti drone atau robot industri, diperlukan penyesuaian pada arsitektur dan proses pelatihannya agar mampu menghadapi karakteristik lingkungan yang kontinu, nonlinier, dan berlangsung secara *real-time*. Langkah pertama adalah mengubah permasalahan kontrol menjadi masalah pembelajaran penguatan (*reinforcement learning*), di mana kondisi sistem seperti posisi, kecepatan, orientasi, atau sudut motor direpresentasikan sebagai *state*, sedangkan sinyal kontrol seperti gaya dorong, torsi, atau kecepatan motor dianggap sebagai *action*. DQN pada dasarnya dirancang untuk ruang aksi diskret, maka ruang aksi kontinu perlu diubah menjadi bentuk diskret (*discretization*).

5. Assignment

Pada praktikum ke-5 ini dikembangkan sebuah sistem untuk mengumpulkan data gestur tangan secara real-time dengan memanfaatkan MediaPipe dan OpenCV. Sistem ini berfungsi untuk mendeteksi keberadaan tangan, menandai posisi setiap sendi (*landmark*), serta menyimpan koordinat titik-titik tersebut ke dalam **file CSV** sebagai dataset. Proses dimulai dengan




inisialisasi modul `mp.solutions.hands` dari MediaPipe yang digunakan untuk mendeteksi tangan, serta `mp.solutions.drawing_utils` yang berfungsi menggambar *landmark* pada citra video. Sebelum proses pelacakan dimulai, program terlebih dahulu memeriksa keberadaan file **hand_joints.csv**. Jika file tersebut belum ada, sistem akan otomatis membuatnya dan menambahkan header berisi informasi seperti nomor frame, jenis tangan (kiri atau kanan), ID titik sendi (*joint_id*), serta nilai koordinat x, y, dan z.

Kamera diaktifkan menggunakan `cv2.VideoCapture(0)` untuk menangkap citra secara langsung. Setiap frame yang diambil dikonversi ke format RGB agar sesuai dengan input yang dibutuhkan oleh MediaPipe. Proses deteksi dilakukan menggunakan model `Hands()`, yang mampu mengenali hingga dua tangan dengan tingkat kepercayaan minimum 0,7 baik untuk deteksi maupun pelacakan. Jika tangan berhasil terdeteksi, sistem akan menggambar *landmark* dan koneksi antar sendi menggunakan fungsi `mp_drawing.draw_landmarks()`. Setiap titik sendi diberi label nomor (0–20) dan dibungkus dengan bounding box berwarna hijau agar area tangan yang terdeteksi terlihat lebih jelas. Di atas kotak tersebut, sistem juga menampilkan label “*Right Hand*” atau “*Left Hand*” berdasarkan hasil klasifikasi dari MediaPipe.

Seluruh hasil deteksi, termasuk koordinat x, y, dan z dari setiap titik sendi, disimpan secara otomatis ke dalam file CSV di setiap frame. Dataset ini dapat dimanfaatkan pada tahap berikutnya, misalnya untuk melatih model machine learning seperti SVM dalam mengenali gestur tangan. Program berjalan secara real-time hingga pengguna menekan tombol Esc, setelah itu kamera dan seluruh jendela aplikasi akan ditutup. Melalui kombinasi MediaPipe sebagai alat ekstraksi fitur dan OpenCV sebagai sarana visualisasi, sistem ini mampu menghasilkan dataset koordinat tangan yang akurat, terstruktur, dan dapat dijadikan fondasi penting dalam pengembangan sistem pengenalan gestur tangan berbasis pembelajaran mesin.

6. Data dan Output Hasil Pengamatan

Data dan hasil yang diperoleh waktu pengamatan sebagai berikut.

No	Dokumentasi	Deteksi	Posisi	Keterangan
1		Jumlah tangan terdeteksi 1, bagian tangan kanan	Seluruh jari tangan kanan terlihat terbuka lebar dan jelas pada tampilan.	Garis berwarna hijau tampak menghubungkan setiap sendi.
2		Jumlah tangan terdeteksi 1, bagian tangan kiri	Seluruh jari tangan kiri terlihat terbuka lebar dan jelas pada tampilan.	Garis berwarna hijau menghubungkan setiap sendi pada tangan, sementara titik-titik berwarna merah menandai posisi masing-masing sendi dengan jelas
3		Jumlah tangan terdeteksi 2, bagian tangan kiri dan kanan	Seluruh jari tangan kiri dan kanan terlihat terbuka lebar dan jelas pada tampilan.	Garis hijau berfungsi sebagai penghubung antar sendi, sedangkan titik-titik merah menunjukkan posisi setiap sendi secara jelas dan teratur.

7. Kesimpulan

Berdasarkan hasil praktikum, sistem deteksi tangan berbasis MediaPipe dan OpenCV mampu mengenali kedua tangan, baik yang kanan maupun kiri secara *real-time* dengan tingkat akurasi yang memuaskan. Setiap tangan dideteksi melalui 21 titik sendi utama, yang kemudian dihubungkan dengan garis hijau dan ditandai menggunakan titik merah pada masing-masing sendi. Tampilan visual deteksi ini terlihat stabil dan konsisten, baik saat hanya satu tangan maupun keduanya muncul dalam satu frame gambar. Sistem juga secara otomatis membedakan antara tangan kiri ("*Left Hand*") dan tangan kanan ("*Right Hand*"), serta menyajikan hasil deteksi dengan jelas melalui *bounding box*. Lebih lanjut, semua koordinat titik-titik tangan berhasil dicatat dan disimpan dalam format file CSV, yang memungkinkan data tersebut digunakan untuk melatih model klasifikasi gestur, misalnya dengan algoritma *Support Vector Machine* (SVM). Secara keseluruhan, perpaduan antara MediaPipe dan OpenCV membuktikan diri sebagai solusi yang efektif, responsif, dan andal dalam mendeteksi posisi serta pola gestur tangan manusia.

8. Saran

Untuk praktikum selanjutnya, sistem ini bisa ditingkatkan dengan menambahkan beragam jenis gestur tangan, sehingga proses klasifikasi menjadi lebih fleksibel dan adaptif terhadap variasi. Pengujian disarankan dilakukan di bawah berbagai kondisi pencahayaan serta sudut pengambilan gambar kamera, guna memperkuat ketangguhan deteksi secara keseluruhan. Di samping itu, sistem dapat dikembangkan lebih jauh untuk mendeteksi lebih dari dua tangan sekaligus atau bahkan interaksi di antara tangan-tangan tersebut.

9. Daftar Pustaka

- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). The MIT Press.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533.

